

DS-5343

WHAT: Abstracting the data

GERMAIN GARCIA ZANABRIA

UNIDAD 1



Índice



1. Tipos de conjuntos de datos
2. Tipos de atributos
3. Secuenciales, divergentes, cíclicos
4. Agregación de datos (temporal y geoespacial)
5. Derivación de nuevos datos.




Objetivos de la Sesión

En esta sesión, se abordará la **abstracción de los datos** y la clasificación de los distintos **tipos de conjuntos de datos y atributos**. Se explorarán los atributos **secuenciales, divergentes y cíclicos**, así como las técnicas de **agregación de datos** en contextos temporales y geoespaciales. Además, se explicará el proceso de derivación de nuevos datos a partir de los existentes, permitiendo una mejor comprensión y transformación de la información para su análisis.



Libro

Visualization Analysis and Design, Tamara Munzner



1.

Abstracción de Datos



What?

Why?

How?

What?

Datasets

➔ Data Types


➔ Items ➔ Attributes ➔ Links ➔ Positions ➔ Grids

➔ Data and Dataset Types


Tables	Networks & Trees	Fields	Geometry	Clusters, Sets, Lists
Items	Items (nodes)	Grids	Items	Items
Attributes	Links	Positions	Positions	
	Attributes	Attributes		

➔ Dataset Types


➔ Tables



➔ Multidimensional Table




➔ Networks



➔ Trees



➔ Fields (Continuous)



➔ Geometry (Spatial)



Attributes

➔ Attribute Types

➔ Categorical



➔ Ordered

➔ Ordinal



➔ Quantitative



➔ Ordering Direction

➔ Sequential



➔ Diverging



➔ Cyclic



➔ Dataset Availability

➔ Static



➔ Dynamic



¿Por qué abstraemos los datos?

Diferentes tipos de atributos → diferentes representaciones


Diferentes tipos de conjuntos de datos → diferentes idioms de visualización disponibles

¿Qué necesitamos para abstraer?

What?

Why?

How?



- **Dataset type:** (e.g., table, network, temporal ...)
- **Attribute types:** (e.g. categorical, ordinal, quantitative)
- **Ordering direction:** (e.g. sequential, diverging, cyclical)
- **Data availability:** (e.g. dynamic, static)

2.


Tipos de conjunto de Datos




Tipos de Datasets

→ Dataset Types


→ Tables



→ Networks




→ Fields (Continuous)



→ Geometry (Spatial)



→ Multidimensional Table



→ Trees



+ Temporal!

TABLAS

- La gran mayoría de los conjuntos de datos
- Atributos (columnas) + elementos (filas)
- Otros tipos de conjuntos de datos suelen almacenarse como una combinación de tablas

price	brand	model	title_status	mileage	color	lot
21500	ford	f-150	clean vehicle	76876	gray	167783132
7500	nissan	door	clean vehicle	58126	black	167598085
10700	chevrolet	trax	clean vehicle	44280	red	167792666
23100	dodge	charger	clean vehicle	12265	silver	167735423
33800	dodge	durango	clean vehicle	15003	black	167734879
4140	ford	door	clean vehicle	40747	white	167656519
13900	nissan	rogue	clean vehicle	38760	white	167762102
15700	ford	cutaway	clean vehicle	75862	white	167780452
1150	ford	door	salvage insurance	123349	red	167652717
26100	ford	f-150	clean vehicle	32149	white	167741409
14000	ford	fusion	clean vehicle	50513	white	167749355
22500	ford	door	clean vehicle	43646	black	167780692


Sample data from Kaggle's US Cars dataset




TABLAS

- La gran mayoría de los conjuntos de datos
- Atributos (columnas) + elementos (filas)
- Otros tipos de conjuntos de datos suelen almacenarse como una combinación de tablas

→ Tables



→ Multidimensional Table



FILE FORMATS

Comma Separated File (CSV)

```
price,brand,model,title_status,mileage,color,lot
21500,ford,f-150,clean vehicle,76876,gray,16778313
7500,nissan,door,clean vehicle,58126,black,1675980
10700,chevrolet,trax,clean vehicle,44280,red,16779
23100,dodge,charger,clean vehicle,12265,silver,167
33800,dodge,durango,clean vehicle,15003,black,1677
4140,ford,door,clean vehicle,40747,white,167656519
13900,nissan,rogue,clean vehicle,38760,white,16776
15700,ford,cutaway,clean vehicle,75862,white,16778
1150,ford,door,salvage insurance,123349,red,167652
26100,ford,f-150,clean vehicle,32149,white,1677414
14000,ford,fusion,clean vehicle,50513,white,167749
22500,ford,door,clean vehicle,43646,black,16778069
```

JSON

```
[
  {
    "price": 21500,
    "brand": "ford",
    "model": "f-150",
    "title_status": "clean vehicle",
    "mileage": 76876,
    "color": "gray",
    "lot": 167783132
  },
  {
    "price": 7500,
    "brand": "nissan",
    "model": "door",
    "title_status": "clean vehicle",
    "mileage": 58126,
    "color": "black",
    "lot": 167598085
  },
  {
    "price": 10700,
    "brand": "chevrolet",
    "model": "trax",
    "title_status": "clean vehicle",
    "mileage": 44280,
    "color": "red"
  }
]
```

TEMPORAL

- Tabular + atributo relacionado con el tiempo
- Agregaciones
- Cíclico
- Eventos o intervalos
- Patrones de estacionalidad

NETWORK


- Nodos + enlaces
- Atributos en ambos
- Idiomas de visualización de redes
- Análisis de redes

¿CÓMO SE ALMACENAN LAS REDES?

- 2 archivos
- Json file
- Matriz de Adyacencia
- Algoritmo de generación

- ## ¿CÓMO SON ALMACENADOS?

- Table
- JSON file
- Algoritmos de generación





GEOMETRY

- Localización (Usualmente latitud/longitud)
- 2D o 3D
- Inherente al shape
- Puntos, rutas, shapes



- Continuo
- Sampled

FIELDS



DATA AVAILABILITY

- **Estático** 📌 los datos no cambian
- **Dinámico** 📌 los datos se actualizan constantemente (por ejemplo, precios de acciones)
- Para datos dinámicos, se requiere un punto de acceso a los datos

3.

Tipos de Atributos



Attributes

➔ Attribute Types

➔ Categorical



➔ Ordered

➔ Ordinal



➔ Quantitative



- Categórico
- Ordinal
- Cuantitativo

CATEGÓRICO

- Sin orden
- Ejemplo: nombres, países, tipos
- Debe representarse con canales visuales que no transmitan orden

ORDINAL

- Tiene orden implícito
- Pero, no se puede hacer operaciones aritméticas
- Puede ser incluso numérico
- Ejemplo:...

CUNATITATIVO

- Ordenados
- Puede hacer operaciones aritméticas
- Puede ser divergente o secuencial
- Ejemplo:...

ORDEN

➔ Ordering Direction

→ Sequential



→ Diverging



→ Cyclic



- Existe un rango completo con un mínimo claro
- Se pueden realizar operaciones aritméticas
- Ejemplo: edad, goles , precio 
- **Existe un punto medio**
- **Dos direcciones opuestas**
- A veces, el punto medio no es cero
- Ejemplo: temperatura, ingresos, índice de afiliación política
- Los datos siguen un ciclo
- No hay un punto de inicio definido (?)
- Se pueden representar con canales visuales cíclicos
- Ejemplo: días de la semana, horas del día

4.

Agregación de Datos



DATOS ESPACIALES

Ejemplo: contar los votos por:

- Departamento
- Ciudad
- País
- Código postal (¿Puede abarcar múltiples distritos? 🙄)
- Áreas personalizadas

DATOS TEMPORALES

2020 June 27 5:25PM

2020 June 27 5:00PM

2020 June 27

2020 June

2020 Q1

2020

2020 June 27 5:25PM

Week 26 of the year

5:00 - 6:00 PM

Saturday

June



ABSTRACCIÓN DE DATOS

Datos que no tienen una
representación Natural

Work Log/Diary


File Edit View Insert Format Data Tools Add-ons Help All changes saved in Drive

enricobertini@gmail.com

Comments Share


fx writing related work (interaction part)

	A	B	C	D	E	F	G	H
1	Date	Start	End	Duration	Project	Type		Description
3	12/23/2016	9:20			FILWID	write	Elk Run	writing blog post on deep work visualization
4	12/8/2016	12:00			Scientific Paper - Climate Governance	think/write	Home	
5	12/7/2016	11:55	12:30		NSF CAREER	think	Home	thinking what to do
6	12/8/2016	19:15	20:00		NSF CAREER	think	Home	thinking what to do
7	11/22/2016	11:55	12:55		NSF CAREER	write	Home	writing draft 2/1/16
8	11/16/2016	1:15	2:00	0:45	NSF CAREER		Tandon	writing data management plan
9	11/16/2016	2:30	4:35	2:05	NSF CAREER		Tandon	writing framework - draft
10	11/16/2016	4:40	5:45	1:05	NSF CAREER		Tandon	a bit of everything
11	11/16/2016	6:15	7:45	1:30	NSF CAREER		Tandon	proofreading
12	11/16/2016	9:00	12:00	3:00	NSF CAREER		Tandon	proofreading
13	11/15/2016	9:25	9:55	0:30	NSF CAREER	write	Elk Run	writing comments with
14	11/15/2016	13:15	13:35	0:20	NSF CAREER	write	Tandon	writing abstract section
15	11/15/2016	14:55	16:00	1:05	NSF CAREER	read	Tandon	re-reading abstract
16	11/15/2016	22:00	22:45	0:45	NSF CAREER		Tandon	revision abstract - readable response
17	11/15/2016	23:10	0:45		NSF CAREER		Tandon	writing broader impacts - project summary
18	11/14/2016	11:55	12:55	1:00	NSF CAREER	write	Elk Run	writing task 2
19	11/14/2016	14:30	15:15	0:45	NSF CAREER	write	Home	writing task 2
20	11/14/2016	19:30	20:00	0:30	NSF CAREER	write	Tandon	writing task 2
21	11/14/2016	20:35	21:00	0:25	NSF CAREER	write	Tandon	writing task 2
22	11/14/2016	21:20	22:10	0:50	NSF CAREER	write	Tandon	writing comments with
23	11/13/2016	8:05	8:05	1:50	NSF CAREER	write	Bobcat	writing task 2
24	11/13/2016	10:10	11:40	1:30	NSF CAREER	write	Bobcat	writing task 2
25	11/13/2016	18:45	19:25	0:40	NSF CAREER	write	Bobcat	writing task 2




ABSTRACCIÓN DE DATOS

Datos que no tienen una
representación Natural



LOS USUARIOS PUEDEN CAMBIAR, QUE VISUALIZAR Y COMO VISUALIZAR



5.

Ejercicios



From Paper to WHAT (Data Abstraction)

“Good visualizations start with correct data abstraction.”

Goal

Understand how research papers apply the
“**What to Visualize**” framework.

You will:

- Read a visualization research paper
- Identify how data is abstracted
- Translate it into Munzner’s WHAT framework

From Paper to WHAT (Data Abstraction)

From the WHAT framework, we must identify:

- Dataset type
- Attribute types
- Ordering
- Data transformations

Select **1 research paper** (IEEE VIS, EuroVis, TVCG, etc.)

Then analyze:

1. Problem & context
2. Data abstraction (WHAT)
3. Transformations
4. Short critique

During this class:

1. Search for a visualization research paper
2. Select **one paper**
3. **Show it to the professor for approval**






You must get approval before continuing



IDENTIFIQUE – TIPO DE DATO – ATRIBUTOS

OmniSci: Mapas de Tweets






PARTICIPACIÓN

Tómense algunos minutos para hablar discutir en grupo y criticar una de estas visualizaciones.

1. <http://hint.fm/wind/> (la original)
2. <https://www.accuweather.com/en/us/cambridge/02139/winter-weather-forecast/329319>
(Radar and maps)
3. <https://www.windy.com/?2022013003,43.676,-68.807,6>
4. <https://earth.nullschool.net/#current/wind/surface/level/orthographic=-65.91,40.65,3843>
5. <https://www.windfinder.com/#6/41.1456/-66.3873>



NESTED MODEL



Domain situation

Observe target users using existing tools



Data/task abstraction



Visual encoding/interaction idiom

Justify design with respect to alternatives



Algorithm

Measure system time/memory

Analyze computational complexity

Analyze results qualitatively

Measure human time with lab experiment (*lab study*)

Observe target users after deployment (*field study*)

Measure adoption

NESTED MODEL

Diseño centrado en el usuario

Entendimiento del diseñador

Usuario

Abstracción del dominio

Tareas

Diseño de la visualización

Implementación



Domain situation

Observe target users using existing tools



Data/task abstraction



Visual encoding/interaction idiom

Justify design with respect to alternatives



Algorithm

Measure system time/memory

Analyze computational complexity

IDENTIFICAR

DISEÑAR



NESTED MODEL

Design Study

Technique

TOP-DOWN
“Problem-
driven”

BOTTOM-UP
“Technique-
driven”



Domain situation

Observe target users using existing tools



Data/task abstraction



Visual encoding/interaction idiom

Justify design with respect to alternatives



Algorithm

Measure system time/memory

Analyze computational complexity

NESTED MODEL

Errores
propagados
a través del
modelo!!



Domain situation

Observe target users using existing tools



Data/task abstraction



Visual encoding/interaction idiom

Justify design with respect to alternatives



Algorithm

Measure system time/memory

Analyze computational complexity



Domain situation

Observe target users using existing tools



Data/task abstraction



Visual encoding/interaction idiom

Justify design with respect to alternatives



Algorithm

Measure system time/memory

Analyze computational complexity

Explicación de las amenazas en cada nivel

1.Domain Situation (Situación del Dominio)

1. Representa el **contexto real** donde se aplicará la visualización.

2. Amenazas:

1. **Comprensión incorrecta del dominio:** si no se entiende bien el problema del usuario, la solución visual no será efectiva.

2. **Suposiciones erróneas sobre los usuarios y sus necesidades.**

2.Data/Task Abstraction (Abstracción de Datos/Tareas)

1. Traduce el problema del dominio en una forma que pueda representarse visualmente.

2. Amenazas:

1. **Elección incorrecta de atributos o datos:** si los datos no representan bien la realidad del problema.

2. **Definición errónea de las tareas del usuario:** si las necesidades no se abstraen correctamente la visualización podría ser inútil.

3. **Este es el paso más difícil**, como se menciona en el modelo original.

1. Visual Encoding/Interaction Idiom (Codificación Visual/Idioma de Interacción)

1. Se decide cómo representar los datos visualmente y cómo interactuar con ellos.
2. **Amenazas:**
 1. **Elección incorrecta de gráficos, escalas, colores, etc.**
 2. **Falta de interactividad o sobrecarga visual** que dificulta la comprensión.
 3. **No adaptar la visualización a las habilidades cognitivas del usuario.**

2. Algorithm (Algoritmo)

1. Implementación computacional que hace posible la visualización.
2. **Amenazas:**
 1. **Errores en el procesamiento de datos.**
 2. **Algoritmos ineficientes o sesgados** que afectan la representación visual.
 3. **Limitaciones computacionales que impiden escalar la visualización.**

UTEC
UNIVERSIDAD DE INGENIERÍA
Y TECNOLOGÍA

